数据挖掘大作业实验报告

互联网广告分类器设计与训练

胡玮玮(2006011293) 孔祥欣(2006011299) 徐恺(2006011281)
清华大学计算机科学与技术系 62 班
{huww06, kxx006, jaguarxk000}@gmail.com

摘要:

文本分类是将自然文本根据内容自动分为预先定义的一个或几个类别的过程。本文介绍了数据挖掘课程中提出的互联网广告分类器设计与训练实验的实施过程。在该实验中，搭建了一个比较完善的实验系统，可以进行再次利用。实现了特征频率 TF 和χ^2统计量 CHI 特征选择算法以及 FOIL 算法和 PRM 分类算法，通过采取不同算法配对并设置不同参数的方式进行实验结果比较，并进行一定的分析。

关键字： 文本分类； 特征选择； 分类算法；

0 引言

近年来随着互联网的不断发展，产生了各种各样的电子数据，如何在海量的数据中挖掘出有用的信息成为了一个新的课题。在这个背景下，我们学习了数据挖掘课程，并利用所学的知识设计与实现一个基于文本的分类器，旨在能够对符合一定特征的数据进行分类。

1 实验内容

数据挖掘课程提出了互联网广告分类器设计与训练项目。项目提供了一个数据集，其中包括了在互联网页面上呈现出的可能广告，并提供了若干属性，对于离散的属性值来说只有 0 和 1 两种分类结果。还包括了三个连续的属性，包括图片长度、宽度、比例等。除此以外提供了一些数据，针对每一个记录（instance）将其定义为广告（ad）或者非广告（nonad）。

项目要求从这些提供的数据中挖掘出适当的有用信息，以这些有用的信息作为依据，对其他给定的若干数据进行分类，判定是否属于广告。

项目建议使用 weka 工具进行实验，同时鼓励自己编程实现数据挖掘的过程，或者对相关算法进行适当的改进。

2 算法分析

我们首先对这个项目的要求进行分析，了解项目的目的，以及提供的数据集的格式。进而熟悉数据挖掘的流程，经过课堂的学习和查阅相关论文，我们认识如下：

数据挖掘过程中存在如下两个名词，一个是训练集，一个是测试集以及相应的标准答案，我们需要做的事情是从训练集中训练出一个分类器，进而使用这个分类器对测试集中的数据进行测试，与标准答案比较即可得到该分类器的效果。一个典型的分类过程包括如下几个步骤：数据预处理→特征选择→训练分类器→分类。因此我们将从以上的四个部分来对我们的算法进行介绍。

2.1 数据预处理

在进行数据预处理之前，我们首先需要认识项目已经提供给我们的数据文件格式。我们并没有使用助教已经构造好的 ad.arff 文件，相反我们使用了 ad.names 和 ad.data 两个文件。下面进行分别介绍：

ad.name 文件：该文件的主要作用是提供了数据的若干属性，其中一条典型的语句如下格式：

url*likesbooks.com: 0,1.

其中“*”号之前的“url”表示该属性的类别是一个 url，“*”号与“：”之间的 likesbooks.com 表示

该属性的名称，而“：”以后的值以“，”为间隔分别表示该属性的取值范围。

ad.data 文件：该文件的主要作用是提供了所有的相关数据，其中一条典型的语句如下格式：

125,125,1.0,1,0+,1+ ,ad.

假设在 ad.name 文件中属性个数为 n，那么在以上的一条数据中，以“，”为分隔符，应该可以得到 n+1 个值，其中前 n 个值分别对应每一个属性的取值，最后一个值标记该条记录是否是广告，“ad”表示该记录为广告，“nonad”表示该记录非广告。

了解完了文件格式以后，下面我们来进行数据处理，在导入文件的过程中，我们进行了如下处理：

首先读取 ad.name，我们定义了一个 Vector<String> attribute;用来保存所有属性，读完以后得到一个属性数目 attributes。进而读取 ad.data，我们定义了 Vector<String> dataString;来保存原始的数据，读完以后得到一个记录条数 instances。

然后我们针对 dataString 中的内容进行处理，对于其中的每一条记录，首先根据后缀判断该条记录是否是广告，并将该记录保存到 Vector<Integer> type;中。然后通过“，”分词，当值为“？”即表示该值缺失，那么将其设置为“0”，由于前三列为连续值属性，所以对其进行离散化，采用在最大与最小值之间进行均分的方式。当这些都处理完毕以后将数据保存至 int [][]data 中。到此为止，数据处理结束，已经给下一步骤提供了比较符合规范的数据。

2.2 特征选择

以上数据经过处理以后虽然比较规范，但是可以发现它们具有很高的维度，如果以这样的训练集来训练分类器的话那么对大大影响训练的效率。因此需要对数据进行降维操作。传统的特征选择算法有特征频率、期望交叉熵、信息增益、χ^2 统计量等方法。在本次实验中我们实现的算法有特征频率 TF 和 χ^2 统计量 CHI 算法。下面进行详细介绍。

2.2.1 特征频率 TF

特征频率（Term Frequency, TF）指文本集中特征词 t 出现的次数，是最简单的特征选择方法。它认为特征在文本集中出现次数越多，对文本分类的贡献越大。在本次实验中，通过 int []frequency 数组来对各个特征词出现的次数进行统计，设置域值 TFYIELD，当特征词出现次数大于该域值时选择此特征项。本实验中选择 Vector<Integer>[] processedData;来保存经过特征选择以后的数据，Vector<Integer> result;用来保存经过选择以后的特征词的序号。

2.2.2 χ2 统计量 CHI

χ^2 统计量（Chi-square, CHI）的主要思想是：认为词条与类别之间没有独立性，并可类比为一个自由度的 χ^2 分布，χ^2 统计量的值越高，词条和类别之间的独立性越小，相关性也就越强。特征词 t 对类别 ci 的 CHI 值公式如下：

$$\chi^2(t, c_i) = \frac{N * (AD - CB)^2}{(A + C) * (B + D) * (A + B) * (C + D)}$$

其中 A 表示属于 ci 类且包含 t 的文档次数，B 表示不属于 ci 类但包含 t 的文档次数，C 表示属于 ci 类但不包含 t 的文档次数，D 表示不属于 ci 类也不包含 t 的文档次数，N 为训练语料中的文档总数，且 N=A+B+C+D，同时满足要求 A*D>B*C。分别计算 t 对每一类的 CHI 值，再用下式计算词条 t 对于整个训练集的 CHI 值。

$$\chi^2_{arg} = \sum_{i=1}^{c} P(c_i)\chi^2(t, c_i)$$

其中 c 表示总类别数，P（ci）表示样本属于 ci 类的频率。在本次实验中设置域值 CHIYIELD，根据以上公式计算的结果，过滤低于该域值的词条，保留高于该域值的词条作为特征项，然后对数据的维数进行降维即可。

2.3 训练分类器

文本分类系统就是按照文本的主题以及之前选择好的特征值，将具体的文本划归为适当类别的计算机系统，该系统的一个核心部分就是现在所说的分类器。分类器是针对已经降维以后的训练集，采用适当的分类算法，得到一个分类函数。该分类函数输入一个测试数据以后能够返回是否属于某一类。在这个过程中，采用的分类算法是一个关键，常用的分类算法主要分为两类：一是基于统计的方法，如简单贝叶斯、k 最近邻方法、类中心向量方法、回归模型、支持向量机等，还有一种是基于规则的方法，如决策树、FOIL 等。在本次实验中，我们采用的是 FOIL 算法以及对 FOIL 算法改进以后的 PRM 算法，具体算法设计如下：

2.3.1 FOIL 算法

FOIL(First Order Inductive Learner)算法是属于贪心型的规则集产生算法。该算法的主要思想是通过不断的尝试条件，找到信息增益最大的条件加入到当前规则中。通过不断的重复条件的产生过程，最终找到

满足覆盖率条件的规则集。

该算法可以用如下伪码描述：

Procedure *FOIL*
  rule set $R \leftarrow \Phi$
  while $|P| > 0$
    $N' \leftarrow N, P' \leftarrow P$
    rule $r \leftarrow empty\_rule$
    while $|N'| > 0$ and
      $r.length < max\_rule\_length$
      find the literal *p* that brings most gain
        according to *P'* and *N'*
      append p to r
      remove from *P'* all examples not satisfying *r*
      remove from *N'* all examples not satisfying *r*
    end
    $R \leftarrow R \cup \{r\}$
    Remove from *P* all examples satisfying *r*
  end
  return *R*

其中，增益(gain)的计算方法如下：

假设当前的正元组为P，负元组为N，当将一个新的条件p加入到规则r中后，新的正元组为P^*，负元组为N^*，则

$$gain(p) = |P^*|\left(\log\frac{|P^*|}{|P^*|+|N^*|} - \log\frac{|P|}{|P|+|N|}\right)$$

由于每次产生规则后都将满足该规则的数据移出正元组，因此该算法每次循环数据规模都在减小，计算过程中的速度将逐渐加快，整体的运行时间较小。

2.3.2 FOIL 算法改进

按照FOIL算法的步骤，如果算法执行过程中没有出现规则长度过长的情况，最终会得到原始数据集的完全覆盖。这将导致一个问题：如果原始数据中存在错误（例如输入错误，这是通常使用的数据集中经常出现的问题），则必然会影响最终的规则产生，因此对FOIL算法进行改进，即并不追求100%的正元组数据覆盖率，当正元组中的数据数量少于预设的值时，即剩余少数顽固数据一直不能得到分类时，算法即停止。这样数据集中个别没有有效的（信息增益大的）规则可以分类的数据便会被忽略。

经过实际的测试，在一定的参数条件下，本次实验使用的数据在数据覆盖率稍稍减少的情况下，正确率有一定的提升，说明以上的思想是可行的。

本次实验最终实现的算法为FOIL改进算法，其主要的参数有：

（1）数据忽略比率。即程序结束时剩余正元组数据与原始正元组数据数量的比值。

（2）最长规则限制。即原始FOIL算法中的最长规则限制（max_rule_length），当规则长于该值时，FOIL算法内层循环退出。

2.3.3 PRM 算法

FOIL 算法在每次计算之后，都会将已经使用过的数据从当前的正元组中移除，也就说已经参与过规则产生的数据将不再参与数据产生。但已经产生的规则对于这些数据来说并不一定是最好的，因此，在PRM 算法中，对每个数据设置一个权值，参与过规则产生的数据的权值将按一定比例减小，从而使得该数据在以后的规则产生过程中被使用的概率减小，而不是直接移除，使得规则生成更合理。

PRM 算法的伪码如下：

Procedure *Predictive Rule Mining*
  set the weight of every example to 1
  rule set $R \leftarrow \Phi$
  $totalWeight \leftarrow TotalWeight(P)$
  while $TotalWeight(P) > \delta \cdot totalWeight$
    $N' \leftarrow N,\ P' \leftarrow P$
    rule $r \leftarrow emptyrule$
    while *true*
      find best literal *p* according to *A'*
      if $gain(p) < min\_gain$ then break
      append *p* to *r*
      for each example *t* in $P' \cup N'$ not satisfying
        r's body
      remove *t* from *P'* and *N'*
    end
  end
  $R \leftarrow R \cup r$
  for each example t in *P* satisfying *r*'s body
    $t.weight \leftarrow \alpha \cdot t.weight$
    end
  end
  return *R*

当然，没有将规则移除将导致每一次循环的规模是恒定的，使得算法的运行时间增长，同时由于已经使用过的数据没有删除，产生的规则的数量将显著增加，进一步影响了算法的效率。

PRM算法的主要参数如下：

（1）结束阈值。算法的结束条件，当数据集的总权值小于原始权值与该阈值乘积时算法结束。
（2）增益下限。内层循环退出条件之一，当最大增益小于该值时，算法的内层循环结束。
（3）衰减比率。每次被使用过的数据的权值将变为原来的衰减比率倍，从而使得再次被使用的可能性下降。

2.4 分类

分类是本次挖掘过程的最后一步，针对训练集采用分类算法训练以后得到分类器，实际上分类器保存的就是很多规则，根据这些规则可以判断某数据是否属于某类。对测试数据进行一定的处理，主要是降维工作，然后将处理之后的数据作为参数传入到分类器中，分类器即可返回一个测试结果。将此测试结果与标准答案集相比较，经过适当计算，可以得到本次挖掘过程的准确率与覆盖率。

3 实验过程

本次实验中助教推荐了 weka 这个工具，但是我们并没有使用，我们是自己编程实现了整个挖掘过程，包括数据预处理、特征选择、训练分类器、分类等步骤。

3.1 实验环境

3.1.1 编程语言：JAVA

3.1.2 操作系统

MS Windows Vista Home Premium
MS Windows XP Professional SP2

3.1.3 编程环境

JDK 1.5.0.0
MyEclipse 7.0
Eclipse 3.4

3.1.4 SVN

Google Code
TortoiseSVN 1.5

3.2 实验系统搭建

本实验系统主要分为分类内核和操作界面两部分，分类内核即为挖掘过程的主要实现部分，而操作界面是为了方便助教重现结果而搭建的。该实验系统目前来看整体框架已经比较完整，可扩展性也比较好，我们现在实现的是两个特征选择算法和两个分类算法，如果以后需要修改的话，只需要再添加新的函数即可以实现新的算法，可以继续为以后数据挖掘方面的实验服务。下面主要介绍该系统的如下两个方面：

3.2.1 分类内核

分类内核是数据挖掘过程的主要实现部分，包括了数据预处理、特征选择、训练分类器、分类等主要部分。各个部分在我们的内核中都有所体现。
（1）数据预处理
本系统中数据预处理部分主要在 PreProcess 类中实现，其中包括了读入训练集文件以及测试文件，我们采用的读入文件不是 arff 类型的，但是我们读入以后可以输出这样的一个将属性值和数据合并到一起的 arff 文件，方便我们使用 weka 工具来验证我们的结果，因为 weka 使用的数据格式是 arff 的。虽然我们没有使用 weka，但是我们还是可以输出这样的一个文件。
（2）特征选择
本系统中特征选择部分主要在 FeatureSelection 类中实现，其中 TF()和 CHI()两个函数分别实现了特征频率和χ^2统计量两个特征选择算法。经过特征选择以后的数据保存在 Vector<Integer>[] processedData 中，选择的属性序号保存在 Vector<Integer> result 中。
（3）训练分类器
本系统中训练分类器主要就是两个算法，都在包 org.kde9.algorithm 中被实现，其中有两个类，一个是 Foil 类实现了 FOIL 算法，一个是 PRM 类实现了 PRM 算法。由于 PRM 是对 FOIL 算法的适当改进，所以我们采取的方式是让 PRM 类继承了 FOIL 类，重载了一些函数，以体现了两个算法之间的联系与不同。
（4）分类
在 org.kde9.entrance 包里的 main 函数中，我们实现了一个无界面的主程序测试。

3.2.2 操作界面

本系统中操作界面部分主要集中在 org.kde9.view 包内，其中实现了一个简单的操作界面，可以帮助用户进行一个简单的数据挖掘过程，并查看结果。具体操作界面如下图所示：

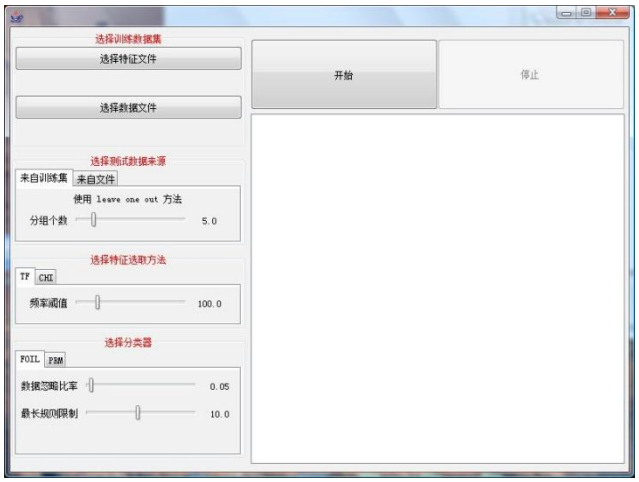

3.3 实验测试

一个典型的对未知数据进行分类的操作是按照如下步骤进行：

（1）通过点击页面左上角的“选择特征文件”和“选择数据文件”两个按钮，选择训练集的特征属性文件和数据文件。

（2）通过点击左边中间的“来自文件”选项卡，然后点击“选择测试数据”按钮输入待测试的数据文件。

（3）在左侧下方选择要采用的特征选择和分类方法，并为每一种方法设置相关参数。

（4）点击右侧上方“开始”按钮，则系统开始进行分类，等待若干时间以后，右侧的主体文本框内将显示分类的结果，针对每一条需要分类的数据给出该数据是否为广告。

4 实验结果

使用该系统对本实验提供的数据进行处理并分类得到如下一些结果：

（1）使用 TF 作为特征选择方法，FOIL 作为分类方法，并将 FOIL 方法中的数据忽略比例设为 0.02，最长规则限制设为 10，通过修改频率域值的大小得到如下结果：

频率域值	特征数量	正确率	覆盖率	运行时间(ms)
0	1558	0.9795	0.9702	293047
50	141	0.977	0.9641	71062
75	74	0.9735	0.967	63921
100	32	0.9714	0.9765	26156
150	23	0.9664	0.9698	23344
200	15	0.9585	0.9755	12125
250	13	0.935	0.9744	8640
300	11	0.9326	0.9769	5969
400	10	0.9214	0.973	4500
500	9	0.9206	0.9709	4375

从以上结果可以看出，随着频率域值的增加，特征数量在逐渐的减少，随之而来的就是正确率的下降和覆盖率的略有上升，而运行时间也随着频率域值的增加而减少很多。

（2）使用 TF 作为特征选择方法，PRM 作为分类方法，并将 PRM 方法中的结束域值设为 0.1，增益下限设为 1，衰减比例设为 0.1，通过修改频率域值的大小得到如下结果：

频率域值	特征数量	正确率	覆盖率	运行时间(ms)
50	141	0.9864	0.9035	222703
100	32	0.9816	0.9099	116047
150	23	0.976	0.9095	87344
200	15	0.9659	0.9248	42985
250	13	0.9485	0.928	31546
300	11	0.948	0.9315	20203
400	10	0.929	0.9375	14187
500	9	0.9288	0.94	13359

从以上结果可以看出和上一组合类似的结论，相比较而言，TF+PRM 组合的运行时间总体上要多于 TF+FOIL 组合。

（3）使用 CHI 作为特征选择方法，FOIL 作为分类方法，并将 FOIL 方法中的数据忽略比例设为 0.05，最长规则限制设为 10，通过修改频率域值的大小得到如下结果：

X^2统计量	特征数量	正确率	覆盖率	运行时间(ms)
-5	1547	0.9805	0.945	239297
-1	1280	0.9727	0.7975	117375
0	217	0.9295	0.9588	58797
1	117	0.9268	0.9613	34469
3	26	0.917	0.9524	14672
5	17	0.8984	0.9659	6578

从以上结果可以看出和上一组合类似的结论。

根据以上的结果得到如下的一些参数设置，使用这些参数针对测试数据集进行测试，首先确定参数设置如下几个：

（1）TF+FOIL，频率域值为 0，数据忽略比例为 0.02，最长规则限制设为 10。

（2）TF+FOIL，频率域值为 50，数据忽略比例为 0.02，最长规则限制设为 10。

（3）TF+FOIL，频率域值为 100，数据忽略比例为 0.02，最长规则限制设为 10。

（4）TF+PRM，频率域值为 200，结束域值为 0.1，增益下限为 1，衰减比例为 0.1。

（5）CHI+FOIL，X^2 统计量为-5，数据忽略比例为 0.02，最长规则限制设为 10。

针对这五种不同的参数，对测试文件进行测试，得到如下结果：（”ad”表示该数据为广告，”nonad”表示该数据位非广告，横坐标表示不同参数设置，纵坐标表示不同测试数据）

	1	2	3	4	5
1	ad	ad	ad	ad	ad
2	ad	ad	ad	ad	ad
3	ad	ad	nonad	ad	ad
4	ad	ad	ad	nonad	ad
5	ad	ad	ad	ad	ad
6	nonad	nonad	nonad	ad	nonad
7	nonad	nonad	ad	ad	nonad
8	nonad	nonad	nonad	nonad	nonad
9	nonad	nonad	nonad	nonad	nonad
10	nonad	nonad	nonad	ad	nonad

从上表结果综合来看，可以得到如下结果，该分类系统认为前五个数据为广告，后五个数据非广告，但是这只是从统计意义来说是这个结果。可以看出参数设置的不同，得到的分类结果差别还是比较大的。

从这些参数设置中可以比较清楚的看出来，该分类系统与特征选择的数量关系非常密切，基本上是正确率与特征数量成正比，但是相反，特征数量越多，导致覆盖率会降低，同时分类所需的时间也会变长。这就要求在设置参数的时候能够在这些因素中寻求一个平衡，使得能够在较快的时间内得到比较好的正确率和覆盖率。

5 实验总结

本实验是数据挖掘课程的期末大实验，刚开始的时候不是很明白实验需要我们做的是什么，于是就按照指导书上的图示使用 weka 工具一步一步的做下去。但是后来很快就发现，如果都是用 weka 做的话，那么很快就可以做完了，但是实际上自己对分类算法并没有很深的理解，于是我们就决定完全不使用 weka 工具，最终就得到了现在的这样一个系统，自己实现了一部分算法，很有成就感。

从实验本身来说，我们组三个人的分工是这样的，胡玮玮负责数据处理、特征选择模块以及实验报告框架的撰写，孔祥欣负责分类算法以及系统 GUI 设计，徐恺负责使用 weka 对分类结果进行预测和校对以及实验报告相关部分的撰写。

从实验的内容来说，刚开始的时候小组同学在一起讨论实现哪些算法。查了很多的论文，发现大部分的论文讲分类系统的设计的时候都很相似，尤其是具体到分类算法的时候，几乎每一篇论文都在重点讲 KNN 等这些常规算法，我们觉得没有新意。而这时候我们联想到前几周做的 paper presentation，我们小组当时做的演示是 CPAR: Classification based on Predictive Association Rules，这篇论文里讲到了 FOIL、PRM、CPAR 等这些算法，我们认为这些与其他的相比更有价值，且分类效果会更好一些。而且，这三个算法是有递进关系的，于是我们就决定实现这些。但是最终由于时间的关系，我们只实现了 FOIL 和 PRM 两个，但是我们同时对 FOIL 有了一定的改进。

本学期经过软件工程大作业以及其他各门专业课的大作业洗礼以后，最后做了这个数据挖掘的大作业。三个同学花了三天时间，从 0 开始，用 2000 多行代码实现了数据挖掘的一个典型过程，并且得到了比较好的结果，还搭建了一个以后可以继续修改和使用的原型系统，我们觉得自己收获了很多。经过这次实验，我们对于数据挖掘的过程也有了更加深刻的认识，更好的巩固了课堂上所学的知识。

最后感谢老师、助教一学期以来的帮助！

参考文献

[1] Xiaoxin Yin and Jiawei Han, CPAR: Classification based on Predictive Association Rules;
[2] 高亚波，文本分类系统的设计与实现，北京交通大学专业硕士学位论文，2008 年 6 月；
[3] 张俊丽，文本分类中的关键技术研究，华中师范大学硕士学位论文，2008 年 5 月；
[4] 余俊英，文本分类中特征选择方法的研究，江西师范大学硕士学位论文，2007 年 5 月；